



Alineamiento de datos NGS



RICARDO A. VERDUGO, Ph.D.

Programa de Genética Humana, ICBM
Facultad de Medicina, U. de Chile

Abril 2021

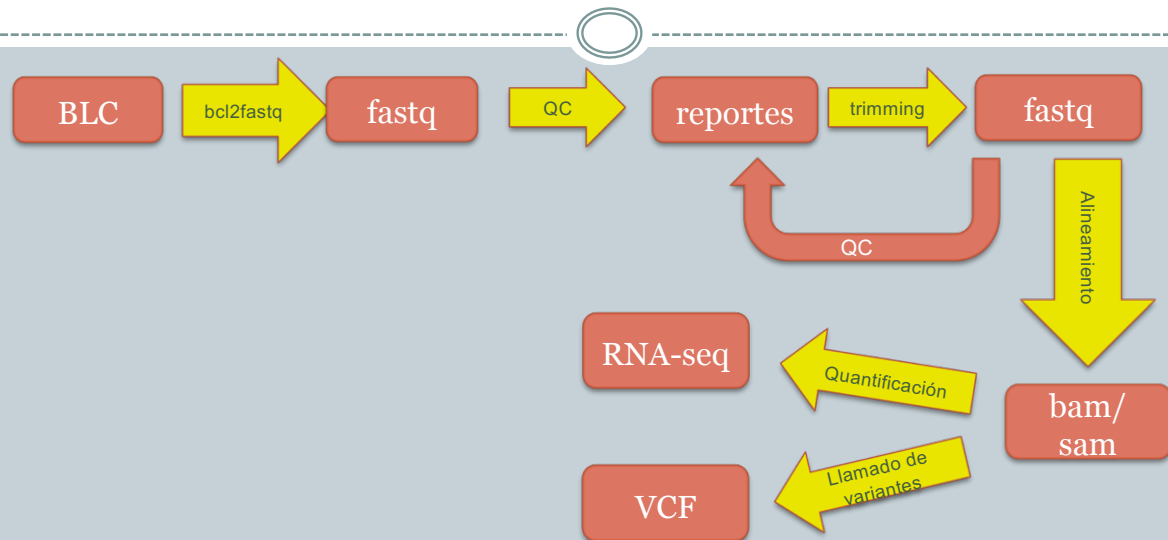
GENOMED-Lab
<http://genomed.med.uchile.cl>

Temas a cubrir



1. Qué es un alineamiento de secuencias
2. Algunos algoritmos
3. Flujos de trabajo NGS con alineamiento
4. Control de calidad del alineamiento

III. Standard NGS Analysis Pipeline



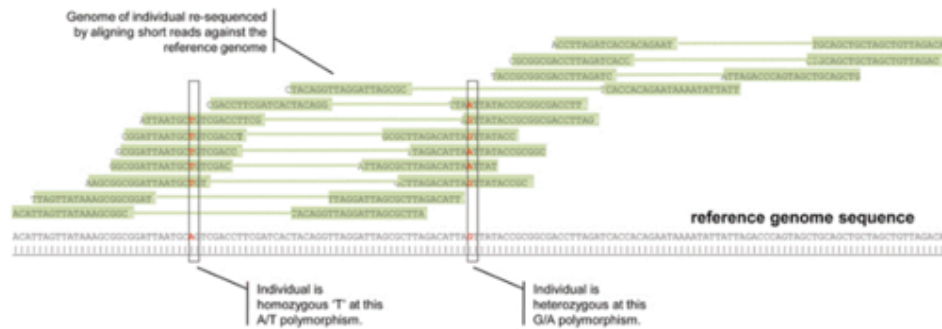
Raw sequencing data: Fastq format

```

@IL31_4368:1:1:996:8507:2
TCCCTTACCCCAAGCTCCATACCTCCTAATGCCACACCTTTACCTTAGGA
+
FFCEFFFEFFFEFFFEFFFEFFFCFC<EEFEFFFCFF<;EEFF=FEE?FCE
@IL31_4368:1:1:996:21421/2
CAAAAACCTTCACTTTACCTGCCGGGTTCCAGTTTACATTCCACTGTTGAC
+
>DBDDb,B9BAA4AAB7BB?7BBB=91;+*@;5<87+*=/@@?9=73=.7)7*
@IL31_4368:1:1:997:10572/2
GATCTTCTGTGACTGGAAGAAAATGTGTACATATTACATTTCTGTCCCATTTG
+
E7=EECE<EEEE98EEEEAEED?BE@AEAB><EEABCEDEC<<EBDA=DEE
@IL31_4368:1:1:997:15684/2
CAGCCTCAGATTCACTTCTCAAAATTCAGTGCAGGCTGAAACAGCAGCAGGAC
+
EEEEDEEE9EAEDEEEEEEEEEECEAAEED<CD=D=*BCAC?;CB,<D@,
@IL31_4368:1:1:997:15249/2
AATGTTCTGAAACCTCTGAGAAAGCAAATATTTATTTAATGAAAAATCCTTAT
+
EDEEC;EEE;EEE?EECE;7AEDEEE07EECEA;D6D>+EE4E7EEE4;E=EA
@IL31_4368:1:1:997:6273/2
ACATTACCAAGACCAAGGAAACTTACCTTGAAGAATTAGACAGTTTCAATTTG
+
EAAFFFEFEFCFAFFAFCCFFEFEF>EFFFFB?ABA@ECEE=<F@DE@DDF;
@IL31_4368:1:1:997:1657/2
CCACCTCTCTCAATGTTTCCATATGCGAGGACTCAGCACAGGTGGATTAAT
(...)
  
```

- Instrument serial #
- Lane
- Swath
- X coord
- Y coord
- Read direction

Alineamiento de lecturas de secuencias



Preguntas clave

1. ¿Qué queremos alinear?
2. ¿Cómo valoraremos un buen alineamiento?
3. ¿Cómo encontramos el mejor alineamiento?

¿Qué queremos alinear?

- **alineación global:** encuentre la mejor coincidencia de ambas secuencias en su totalidad
- **alineación local:** encuentra la mejor coincidencia de subsecuencias
- **alineación semi-global:** encuentre la mejor coincidencia sin penalizar las brechas en los extremos de la alineación

El espacio de posibles alineamientos

- Estos son algunos posibles alineamientos de las palabras ELV y VIS

ELV	-ELV	--ELV	ELV-
VIS	VIS-	VIS--	-VIS
E-LV	ELV--	EL-V	
VIS-	--VIS	-VIS	

¿Cómo valoraremos un buen alineamiento?

- **Función de penalización de espacios (gaps)**

- $w(k)$ = costo de un espacio de largo k en la secuencia
- La más simple es una función lineal: $w(k) = g \times k$
- g es una constante

- **Matriz de substitución**

- $s(a, b)$ indica la puntuación de alinear el carácter a con el carácter b
- La más simple es $s(a, b) = \{+1 \text{ si } a=b, -1 \text{ si } a \neq b\}$

	A	G	C	T
A	1	-1	-1	-1
G	-1	1	-1	-1
C	-1	-1	1	-1
T	-1	-1	-1	1

Valoración de un alineamiento

- El puntaje de una alineación es la suma de los puntajes para pares de caracteres alineados más los puntajes de las brechas
- ejemplo: dada el siguiente alineamiento

VAHV---D--DMPNALSALSDLHAHKL
 AIQLQVTGVVVTDLTKNLGSVHVS KG

El puntaje se calcula:

$$s(V,A) + s(A,I) + s(H,Q) + s(V,L) + 3g + s(D,G) + 2g \dots$$

¿Cómo encontramos el mejor alineamiento?

- ¿Cuál sería el mejor alineamiento de estas dos cadenas de caracteres?

T H A T T I N H A T
C A T I N H A T

1. Aproximación ingenua

1. Enumerar todas las posibles subcadenas de cada cadena
2. Compararlas mediante un puntaje
3. Elegir la pareja de mayor puntaje

Tiempo requerido: $O(n^2) O(n^2) = O(n^4)$


Posibles alineamientos

$$\binom{2n}{n} = \frac{(2n)!}{(n!)^2} \approx \frac{2^{2n}}{\sqrt{\pi n}}$$

Solución por programación dinámica

- **Programación dinámica:** resuelva una instancia de un problema aprovechando las soluciones para subpartes del problema
 - reducir el problema de la mejor alineación de dos secuencias a la mejor alineación de todos los prefijos de las secuencias
 - Evitar recalcular las puntuaciones ya consideradas.
- Utilizado por primera vez en alineación por Needleman & Wunsch, Journal of Molecular Biology, 1970

Alineamiento Global vs Local




Algoritmo de Smith y Waterman

Ejemplo: TGTTACGG vs GGTGACTA

Matriz de sustitución: $s(a_i, b_j) = \begin{cases} +3, & a_i = b_j \\ -3, & a_i \neq b_j \end{cases}$

Penalización por espacios: $W_k = kW_1, W_1 = 2$



https://en.wikipedia.org/wiki/Smith-Waterman_algorithm

Algoritmo de Smith y Waterman

$$H_{ij} = \max \begin{cases} H_{i-1,j-1} + s(a_i, b_j), \\ \max_{k \geq 1} \{H_{i-k,j} - W_k\}, \\ \max_{l \geq 1} \{H_{i,j-l} - W_l\}, \\ 0 \end{cases}$$

$(1 \leq i \leq n, 1 \leq j \leq m)$

Initialize the scoring matrix

	T	G	T	T	A	C	G	G
G	0							
G	0							
T	0							
T	0							
G	0							
A	0							
C	0							
T	0							
A	0							

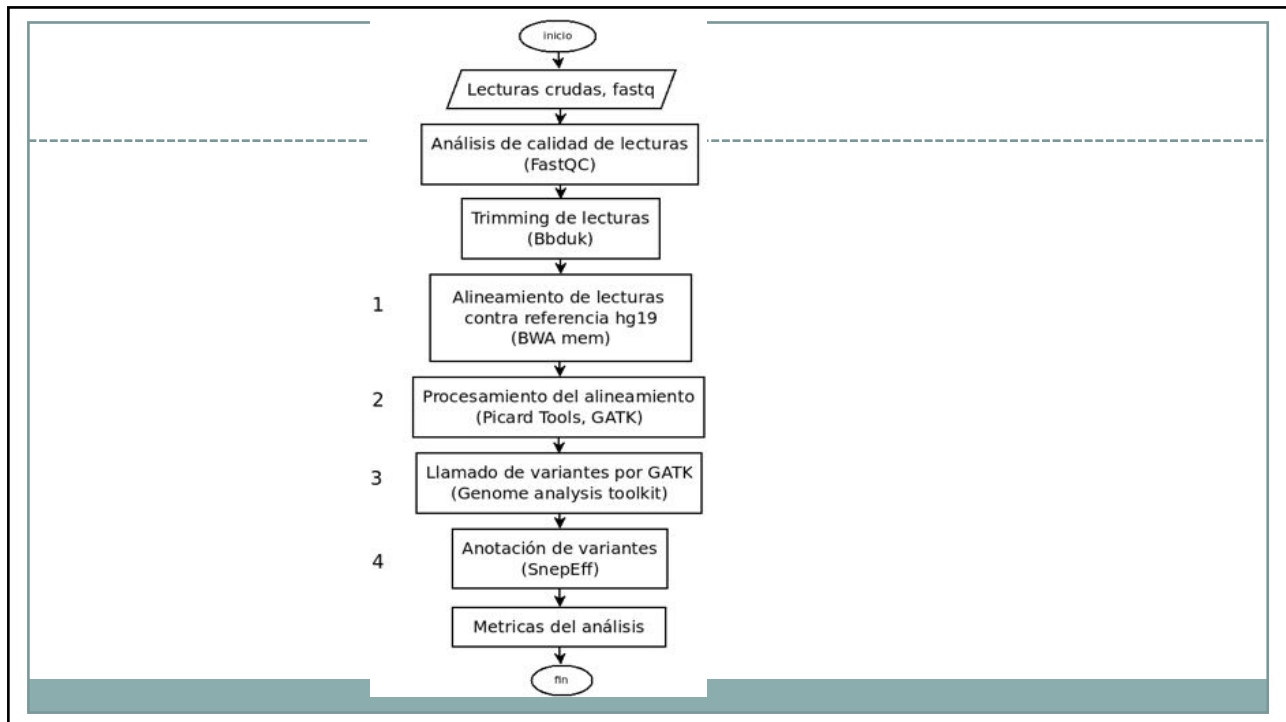
Substitution matrix: $S(a_i, b_j) = \begin{cases} +3, & a_i = b_j \\ -3, & a_i \neq b_j \end{cases}$

Gap penalty: $W_k = kW_1$
 $W_1 = 2$

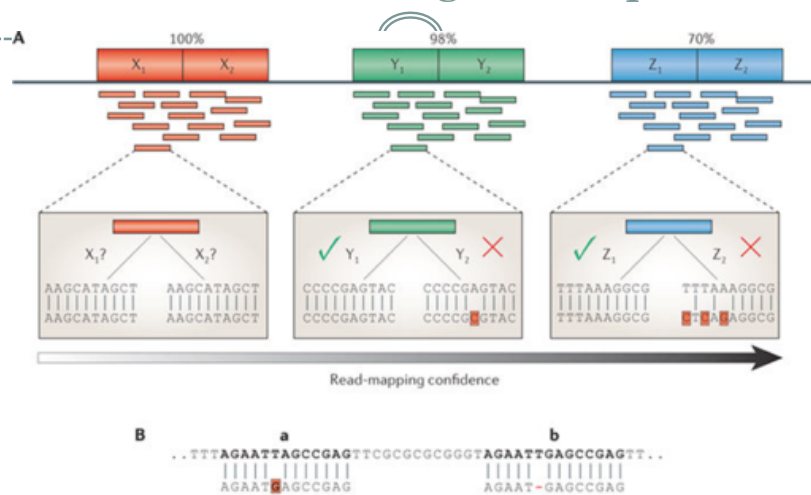
Alineador BWA

Burrows-Wheeler Aligner (BWA) S/W Package

- Use **Burrows-Wheeler Transform** to "index" the human genome and allow memory-efficient and fast string matching between sequence read and reference genome.
- **BWA**: Short-read algorithm, alter the read sequence such that it matches the reference exactly.
- **BWA-SW**: Long-read algorithm, sample reference subsequences and perform Smith-Waterman alignment between the subsequences and the read.
- **BWA-MEM**:
 - Similar features to BWA-SW
 - Long-read alignment
 - Seed and extend with SW
 - Finds larger gaps
 - Faster! Generally supersedes BWA-SW




Alineamiento en Regiones Repetidas



Nature Reviews Genetics 13, 36-46 (January 2012)
doi:10.1038/nrg3117

Nature Reviews | Genetics

Integrative Genomic Viewer



<http://software.broadinstitute.org/software/igv/>

¿Qué mirar en una visualización de alineamiento?

- Cobertura en la región de interés
- Posible sesgo de variantes entre R1 y R2 o por hebra (strand bias)
- Variantes que estén en los extremos
- INDELs en los extremos
- Sustituciones alrededor de los INDELs (realizar realineamiento local)

Métricas básicas de calidad

- % de lecturas mapeados
- % de lecturas únicamente mapeados
- % de lecturas efectivamente mapeados (luego de eliminar duplicados)
- Profundidad promedio (x)
- Cobertura (% de la región blanco que fue cubierta con lecturas)
- Calidad de mapeo (QMAP para cada lectura) -> tasa de error
- Distribución de tamaños de inserto (para librerías pareadas)
- % de lecturas en el blanco (*on target*)
- Enriquecimiento de región blanco (*on target*)

Sesgos de variantes detectadas

